

第7.1节 Boosting方法

中国科学院大学 叶齐祥

qxye@ucas.ac.cn

内容



- 背景介绍
- Adaboost 算法
- Face detection 例子

Adaboost的优点

- 高的分类精度
- 可以让多种分类器集成起来
 - 很多领域都很适用
- 程序上易于实现，运行速度高
- 不易产生overfitting

Adaboost的历史

- Bootstrapping
- Bagging
- Boosting (Schapire 1989)
- Adaboost (Schapire 1995)

Bagging - Aggregate Bootstrapping

- For $i = 1 \dots M$
 - 从训练集合 D 提取 $n^* < n$ 个样本
 - 学习分类器 h_i
- 最终的分分类器是 $h_1 \dots h_i, h_M$ 的投票结果
- 增加了分类器的稳定性


Boosting (Schapire 1989)

- 从训练集合 D 提取 $n_1 < n$ 个样本, 构建 D_1
 - 训练弱分类器 h_1
- 从训练集合 D 提取 $n_2 < n$ 个被 h_1 错误分类的样本, 构建 D_2
 - 训练弱分类器 h_2
- 从训练集合 D 提取 $n_3 < n$ 个被 h_1, h_2 错误分类的样本, 构建 D_3
 - 训练弱分类器 h_3
-
- 最后的分类器是 $h_1, h_2, h_3 \dots$ 的投票结果


Adaboost - Adaptive Boosting

- 对样本不仅仅是采样,还有 加权(re-weight)
- 最终分类器是弱分类器的加权平均
 - 加权线性组合
- 弱分类器
 - -**Weak Learner**: 错误率 $< 50\%$ 的分类器


Adaboost - 示意图



Adaboost - 示意图




第一个分类器




第二个分类器

$$\epsilon_2 = 0.21$$
$$\alpha_2 = 0.65$$


D_3



Adaboost - 示意图




第一个分类器



第二个分类器


$$\epsilon_2 = 0.21$$
$$\alpha_2 = 0.65$$



$$\epsilon_3 = 0.14$$
$$\alpha_3 = 0.92$$

第三个分类器

Adaboost - 示意图



Adaboost – 算法

- 对于给定的训练样本集合 $X = \{(x_1, y_1), \dots, (x_n, y_n)\}$
- $y_i \in \{-1, +1\}$ 表示这些样本的真实标号

- For ($t = 1, \dots, T$)

- 在 $\{1, \dots, n\}$ 构造 D_t
- 找到弱分类器 $h_t: X \rightarrow \{-1, +1\}$

使得分类误差: $\varepsilon_t = P_{D_t} [h_t(x_i) \neq y_i]$ 最小

- 输出最终的假设（分类器）

$$H(x) = \text{sign} \left(\sum_t \alpha_t \cdot h_t(x) \right)$$

Adaboost – 算法

- 改变训练过程中样本集合的重要性（权值） D_t
- $D_1(i) = 1.0/n$
- 给定 D_t 与 h_t 令 $D_{t+1}(i) = \frac{D_t(i)}{Z_t} \cdot \begin{cases} e^{-\alpha_t} & \text{if } y_i = h_t(x_i) \\ e^{\alpha_t} & \text{if } y_i \neq h_t(x_i) \end{cases}$

$$= \frac{D_t(i)}{Z_t} \cdot \exp(-\alpha_t y_i h_t(x_i))$$

○ 其中 Z_t 是归一化常数

$$\alpha_t = \frac{1}{2} \ln \left(\frac{1 - \epsilon_t}{\epsilon_t} \right) > 0$$

- 输出最终的假设（分类器）

$$H_{\text{final}}(x) = \text{sign} \left(\sum_t \alpha_t h_t(x) \right)$$

Adaboost – 算法

- 权值分析

$$f(x) = \sum_t \alpha_t h_t(x) \Rightarrow H_{\text{final}}(x) = \text{sign}(f(x))$$

$$D_{\text{final}}(i) = \frac{1}{n} \cdot \frac{\exp\left(-y_i \sum_t \alpha_t h_t(x_i)\right)}{\prod_t Z_t}$$

$$= \frac{1}{n} \cdot \frac{e^{-y_i f(x_i)}}{\prod_t Z_t}$$

Adaboost – 算法

- 误差分析

- 因为

$$H_{\text{final}}(x) \neq y \Rightarrow yf(x) \leq 0 \Rightarrow e^{-yf(x)} \geq 1$$

- 所以

$$\begin{aligned} \text{training error}(H_{\text{final}}) &= \frac{1}{n} \sum_i \begin{cases} 1 & \text{if } y_i \neq H_{\text{final}}(x_i) \\ 0 & \text{else} \end{cases} \\ &\leq \frac{1}{n} \sum_i e^{-y_i f(x_i)} \\ &= \sum_i D_{\text{final}}(i) \prod_t Z_t \\ &= \prod_t Z_t \end{aligned}$$

Adaboost – 算法

- 误差分析

$$\epsilon_t = 1/2 - \gamma_t$$

$$\text{training error}(H_{\text{final}}) \leq \prod_t \left[2\sqrt{\epsilon_t(1 - \epsilon_t)} \right]$$

$$= \prod_t \sqrt{1 - 4\gamma_t^2}$$

$$\leq \exp\left(-2 \sum_t \gamma_t^2\right)$$

$$\forall t : \gamma_t \geq \gamma > 0$$

$$\text{training error}(H_{\text{final}}) \leq e^{-2\gamma^2 T}$$

Adaboost – 算法

- 多类问题 $y \in Y = \{1, \dots, k\}$

$$h_t : X \rightarrow Y$$

- 一种直观的方法
- 样本权值更新

$$D_{t+1}(i) = \frac{D_t(i)}{Z_t} \cdot \begin{cases} e^{-\alpha_t} & \text{if } y_i = h_t(x_i) \\ e^{\alpha_t} & \text{if } y_i \neq h_t(x_i) \end{cases}$$

- 分类假设

$$H_{\text{final}}(x) = \arg \max_{y \in Y} \sum_{t: h_t(x)=y} \alpha_t$$

$$\alpha_t = \frac{1}{2} \ln \left(\frac{1 - \epsilon_t}{\epsilon_t} \right) > 0$$

Adaboost – 算法

- 多类问题

- 将多类问题转化为二类问题的方法
- 假如一个分类问题的类标号为五种 { a, b, c, d, e }
- 则可以将任何一次分类转化为5个二类问题

$$x, c \rightarrow \left\{ \begin{array}{l} (x, a), -1 \\ (x, b), -1 \\ (x, c), +1 \\ (x, d), -1 \\ (x, e), -1 \end{array} \right.$$

Adaboost – 算法

- 多类问题

$$h_t : X \times Y \rightarrow \{-1, +1\} \text{ (or } \mathbb{R})$$

$$D_{t+1}(i, y) = \frac{D_t(i, y)}{Z_t} \cdot \exp(-\alpha_t v_i(y) h_t(x_i, y))$$

$$\text{where } v_i(y) = \begin{cases} +1 & \text{if } y_i = y \\ -1 & \text{if } y_i \neq y \end{cases}$$

$$H_{\text{final}}(x) = \arg \max_{y \in Y} \sum_t \alpha_t h_t(x, y)$$

○ 可以证明

$$\text{training error}(H_{\text{final}}) \leq \frac{k}{2} \cdot \Pi Z_t$$

Adaboost – 算法

- 多类问题-类别特别多的情况


- 可以为每一个分类编码，编码来自少数的二值分类器

	π_1	π_2	π_3	π_4
a	-	+	-	+
b	-	+	+	-
c	+	-	-	+
d	+	-	+	+
e	-	+	-	-

$x, c \rightarrow \begin{cases} (x, \pi_1), +1 \\ (x, \pi_2), -1 \\ (x, \pi_3), -1 \\ (x, \pi_4), +1 \end{cases}$

- 在分类新样本时，先在二值分类器上进行，然后看分类结果的”编码”跟那一个类别”最近”

Adaboost — 算法





Adaboost – 应用

- 训练样本



Adaboost – 应用

- 特征计算



Adaboost – 应用

- Given example images $(x_1, y_1), \dots, (x_n, y_n)$ where $y_i = 0, 1$ for negative and positive examples respectively.
- Initialize weights $w_{1,i} = \frac{1}{2m}, \frac{1}{2l}$ for $y_i = 0, 1$ respectively, where m and l are the number of negatives and positives respectively.
- For $t = 1, \dots, T$:

1. Normalize the weights,

$$w_{t,i} \leftarrow \frac{w_{t,i}}{\sum_{j=1}^n w_{t,j}}$$

so that w_t is a probability distribution.

2. For each feature, j , train a classifier h_j which is restricted to using a single feature. The error is evaluated with respect to w_t , $\epsilon_j = \sum_i w_i |h_j(x_i) - y_i|$.
3. Choose the classifier, h_t , with the lowest error ϵ_t .
4. Update the weights:

$$w_{t+1,i} = w_{t,i} \beta_t^{1-e_i}$$

where $e_i = 0$ if example x_i is classified correctly, $e_i = 1$ otherwise, and $\beta_t = \frac{\epsilon_t}{1-\epsilon_t}$.

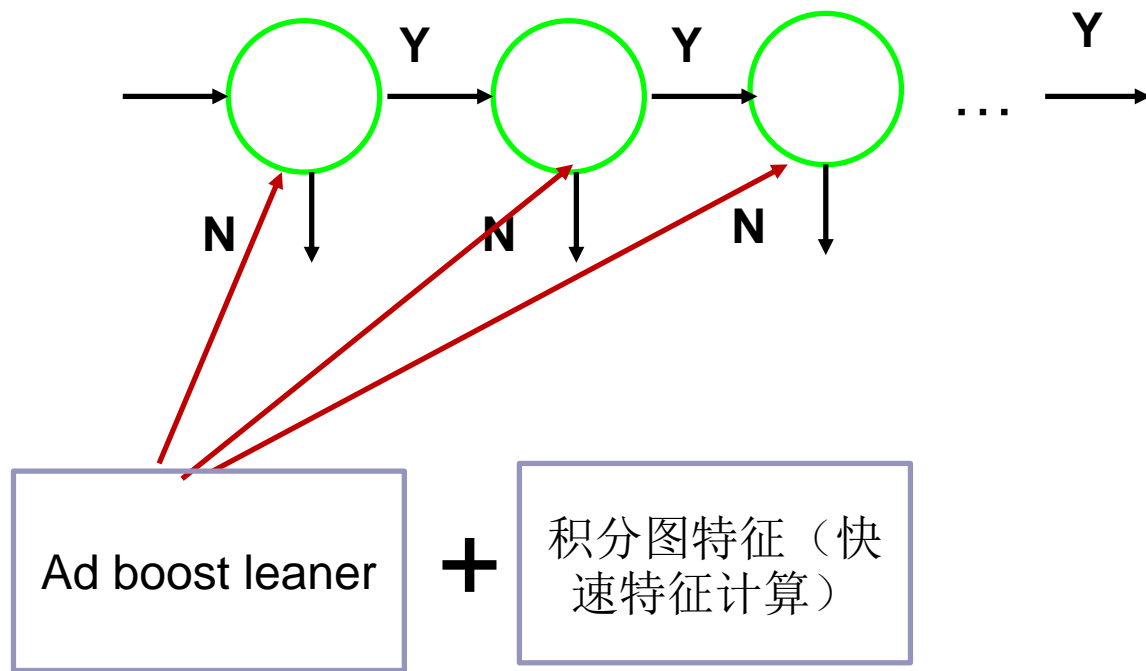
- The final strong classifier is:

$$h(x) = \begin{cases} 1 & \sum_{t=1}^T \alpha_t h_t(x) \geq \frac{1}{2} \sum_{t=1}^T \alpha_t \\ 0 & \text{otherwise} \end{cases}$$

where $\alpha_t = \log \frac{1}{\beta_t}$

Adaboost – 应用



- Cascade 分类器





Adaboost – 应用

● 结果

False detections Detector	10	31	50	65	78	95	110	167	422
Viola-Jones	78.3%	85.2%	88.8%	89.8%	90.1%	90.8%	91.1%	91.8%	93.7%
Rowley-Baluja-Kanade	83.2%	86.0%	-	-	-	89.2%	-	90.1%	89.9%
Schneiderman-Kanade	-	-	-	94.4%	-	-	-	-	-
Roth-Yang-Ahuja	-	-	-	-	(94.8%)	-	-	-	-





Thank you